

Laporan Akhir Unsupervised Retail Transaction & Return Behavioral Analytics Using KMeans

1. Konteks Kasus dan Perspektif Analisis Data

1.1 Latar Belakang

Perkembangan pada dunia e-commerce sudah menjadi tolak ukur perubahan yang signifikan dalam perilaku konsumen. E-commerce menghasilkan volume data transaksi yang besar mengakibatkan perkembangan ini penting bagi perusahaan untuk memahami tiap preferensi pelanggan dan mencari pola penjualan yang dapat diambil untuk meningkatkan pendapatan.

Dataset yang digunakan pada proyek ini adalah sebuah sistem ritel online yang berbasis di Inggris dan berisi catatan transaksi dari transaksi pada sistem tersebut. Pada dataset ini tersedia informasi produk, identitas pelanggan, jumlah pembelian, harga, dan timestamp transaksi. Tujuan pada proyek ini adalah mengidentifikasi pola perilaku pembelian pelanggan dengan menentukan produk terpopuler dan mencari tren penjualan berdasarkan waktu dan lokasi geografis.

Pendekatan yang digunakan pada penelitian ini berupa pendekatan eksploratori yang fokus pada pengungkapan pola dan hubungan pada data, dengan menerapkan teknik analisa data yaitu memproses data mentah menjadi informasi yang bermakna untuk mengungkap pola dan tren agar meningkatkan kinerja bisnis melalui pola yang sudah terungkap.

1.2 Data Analytics Lifecycle

- Pengumpulan Data (Data Collection) Dataset ini merepresentasikan data transaksi yang dikumpulkan dari sistem ritel daring (online retail system).
- Persiapan Data (Data Preparation / Data Wrangling) Data mentah dibersihkan dan ditransformasikan untuk memastikan akurasi dan konsistensi. Proses ini meliputi penanganan nilai yang hilang (missing values), penghapusan transaksi yang tidak valid, serta pembuatan variabel turunan seperti total nilai transaksi.
- Analisis Data Eksploratif (Exploratory Data Analysis / EDA) Dataset yang telah dibersihkan kemudian dianalisis untuk mengidentifikasi pola, tren, dan hubungan antarvariabel menggunakan ringkasan statistik dan teknik visualisasi data.

1.3 Peran Data Wrangling dan EDA

- Proses Data Wrangling dilakukan untuk meningkatkan kualitas data mentah dan mempersiapkannya ke tahap analisis dengan menerapkan strategi **Zero Data Loss**.

Berbeda dari pendekatan konvensional yang membuang data *outlier* atau *missing values*, seluruh baris transaksi berharga tetap dipertahankan.

- Exploratory Data Analysis (EDA) bertujuan untuk memahami karakteristik data secara spesifik melalui statistik deskriptif dan visualisasi. Dalam proyek ini, EDA digunakan untuk mengidentifikasi pola penjualan, perilaku konsumen, performa produk secara individu, dan tren penjualan berbasis waktu. Hasil dari EDA ini diharapkan dapat memberikan gambaran yang jelas tentang bagaimana konsumen berinteraksi dengan sistem ritel tersebut.

2. Data Understanding dan Data Quality

2.1 Deskripsi Dataset

Dataset yang digunakan adalah Online Retail Dataset yang berisi transaksi dari e-commerce yang berbasis di UK pada periode Desember 2010 sampai Desember 2011. Dataset ini berisi 541909 baris dengan 8 kolom sebagai berikut

Kolom	Tipe Data	Deskripsi
InvoiceNo	Categorical/ Identifier	Nomor unik yang ditetapkan untuk setiap transaksi
StockCode	Categorical/ Identifier	Kode produk
Description	Categorical	Deskripsi produk
Quantity	Numerical (Integer)	Jumlah produk yang dibeli per transaksi
InvoiceDate	Datetime	Tanggal dan waktu transaksi terjadi
UnitPrice	Numerical (Float)	Harga per unit produk (GBP)
CustomerID	Identifier	Identifier unik untuk setiap pelanggan
Country	Categorical	Negara asal pelanggan

2.2 Data Quality Issue

Missing Value

Pada kolom CustomerID terindikasi memiliki missing value sebanyak 135.080 baris. Dari data ini dapat dilihat jika sebagian transaksi tidak memiliki pelanggan atau tidak terdeteksi. Pada kolom Description juga memiliki missing value sebanyak 1.454 missing value.

Kolom	Jumlah Missing	Persentase
CustomerID	135.080	24.93%
Description	1.454	0.27%
Kolom lainnya	0	0.00%

Duplicate Value

Teridentifikasi sebanyak 5.268 baris duplikat dalam dataset, yang berpotensi menyebabkan perhitungan tidak akurat

Outlier

Outlier ditemukan pada beberapa kolom dengan menggunakan metode IQR. Outlier dapat menimbulkan distorsi pada tahap analisis

Inkonsistensi Data

Terdapat nilai negatif pada kolom Quantity sebanyak 10.624 baris yang mengindikasikan pengembalian produk atau salah input. Selain itu kolom InvoiceDate awalnya tidak dalam format date.

2.3 Dampak Isu Data Pada Analisis

- **Missing Values:** Data yang tidak lengkap dapat menyebabkan bias dalam analisis berbasis pelanggan. Tanpa CustomerID, tidak mungkin menganalisis perilaku pelanggan individual secara akurat.
- **Outliers:** Nilai ekstrem dapat mendistorsi ukuran statistik seperti mean (rata-rata), sehingga interpretasi tidak merepresentasikan kondisi bisnis yang sebenarnya.
- **Inkonsistensi (Negative Quantity):** Jika nilai negatif tidak dipisahkan atau dihapus, total penjualan akan tidak akurat karena bercampur dengan transaksi pengembalian.
- **Duplicate Data:** Entri duplikat dapat menyebabkan double-counting, sehingga metrik seperti total penjualan atau jumlah transaksi menjadi lebih tinggi dari angka sebenarnya.

3. Data Wrangling & Preparation Process

3.1 Penghapusan Duplikat Persis

Menghapus baris yang identik secara keseluruhan untuk menghindari gandaan pencatatan (double counting) tanpa menghilangkan variasi transaksi riil.

```
df_clean = df_clean.drop_duplicates()
```

✓ 1.6s Python

3.2 Penanganan Missing Values & Retur tanpa Data Trimming

Pelanggan Anonim (Has_CustomerID): Transaksi dengan CustomerID kosong tidak dibuang, melainkan ditandai sebagai indikator transaksi Guest Checkout.

Transaksi Retur (Is_Return): Transaksi dengan Quantity negatif tidak dihapus, melainkan diidentifikasi secara khusus untuk menganalisis perilaku pengembalian barang/pembatalan.

```
df_clean["Is_Return"] = (df_clean["Quantity"] <= 0).astype(int)
df_clean["Has_CustomerID"] = df_clean["CustomerID"].notna().astype(int)
df_clean["InvoiceHour"] = df_clean["InvoiceDate"].dt.hour
```

✓ 0.1s

Python

3.3 Tranformasi Tipe Data

Kolom InvoiceDate diubah menjadi tipe datetime yang awalnya adalah object agar analisis dengan timeline waktu dapat dilakukan

```
df_clean["InvoiceDate"] = pd.to_datetime(df_clean["InvoiceDate"])
df_clean.info()
```

✓ 0.7s

Python

3.4 Feature Engineering

Menambahkan/membuat kolom baru yaitu TotalPrice digunakan untuk mendukung analisis. Kolom ini dibuat dari mengkalikan kolom Quantity dengan kolom UnitPrice


4. Exploratory Data Analysis (EDA)

4.1 Statistik Deskriptif (Key Values)

	count	mean	min	25%	50%	75%	max	std
Quantity	536641.0	9.620029	-80995.0	1.0	3.0	10.0	80995.0	219.130156
InvoiceDate	536641	2011-07-04 08:57:06.087421952	2010-12-01 08:26:00	2011-03-28 10:52:00	2011-07-19 14:04:00	2011-10-18 17:05:00	2011-12-09 12:50:00	NaN
UnitPrice	536641.0	4.632656	-11062.06	1.25	2.08	4.13	38970.0	97.233118
CustomerID	401604.0	15281.160818	12346.0	13939.0	15145.0	16784.0	18287.0	1714.006089
Is_Return	536641.0	0.019728	0.0	0.0	0.0	0.0	1.0	0.139065
Has_CustomerID	536641.0	0.748366	0.0	0.0	1.0	1.0	1.0	0.433952
InvoiceHour	536641.0	13.077154	6.0	11.0	13.0	15.0	20.0	2.447505
TotalPrice	536641.0	18.123861	-168469.6	3.75	9.87	17.4	168469.6	380.656263

- Rentang Nilai Ekstrem: Nilai Quantity (min -80.995 hingga max 80.995) dan TotalPrice (min -168.469,6 hingga max 168.469,6) memiliki variansi raksasa dengan deviasi standar (std) jauh melampaui nilai rata-ratanya (mean), mengonfirmasi distribusi data yang sangat menceng (skewed).
- Keberadaan Transaksi Retur: Nilai minimum negatif pada Quantity, UnitPrice, dan TotalPrice memperlihatkan adanya transaksi pembatalan/pengembalian barang. Rata-rata Is_Return sebesar 0,0197 (1,97%) menunjukkan bahwa ~2% dari total baris transaksi merupakan aktivitas retur.
- Proporsi Pelanggan Terdaftar vs Anonim: Jumlah count pada CustomerID hanya 401.604 baris (~74,8% dari total data), yang diperkuat oleh rerata Has_CustomerID sebesar 0,7483. Artinya, sekitar 25,2% transaksi dilakukan oleh pembeli tanpa akun (guest checkout).
- Pola Jam Transaksi: Rata-rata jam transaksi berada di 13.07 (sekitar pukul 1 SIANG) dengan rentang belanja aktif antara pukul 06.00 pagi hingga 20.00 malam.

4.2 Distribusi Data



Hasil analisis eksplorasi data (EDA) pada variabel Quantity, UnitPrice, dan TotalPrice menunjukkan pola distribusi yang sangat mencentong ke kanan (right-skewed) dengan mayoritas transaksi berkumpul pada nominal kecil. Tampilan titik-titik outlier ekstrem pada visualisasi boxplot disengaja untuk dibatasi agar Kotak Interkuartil (IQR) serta nilai median tetap dapat teridentifikasi secara jelas tanpa tertekan menjadi garis tipis. Meskipun disembunyikan pada grafik agar visualisasi tetap rapi, seluruh data outlier riil ini tetap dipertahankan utuh sesuai pendekatan Zero Data Loss, yang kemudian ditransformasikan menggunakan Symmetric Log dan QuantileTransformer agar siap diproses oleh algoritma K-Means tanpa terdistorsi skala raksasa.

4.3 Top Selling Products & Top Product by Revenue

Top Produk Terlaris (Quantity) :

Visualisasi Top Selling Products menunjukkan bahwa volume penjualan tertinggi didominasi oleh produk suvenir dan perlengkapan dekorasi harian berharga terjangkau, dengan WORLD WAR 2 GLIDERS ASSTD DESIGNS memimpin di posisi puncak (>53.000 unit).


Top Produk Berdasarkan Revenue :

Visualisasi Top Products by Revenue menunjukkan bahwa pendapatan bisnis terbesar dipimpin oleh DOTCOM POSTAGE (>200.000).

4.4 Penjualan berdasarkan Negara

Pasar didominasi penuh oleh UK dengan kontribusi >8 juta


4.5 Analisis Tren Penjualan Berdasarkan Waktu



Visualisasi Monthly Sales Trend menunjukkan adanya pola musiman (seasonality) yang kuat, di mana total pendapatan cenderung stabil di kisaran 500 ribu hingga 700 ribu dari awal hingga pertengahan tahun, kemudian melonjak drastis mulai September hingga mencapai puncaknya pada bulan November (mendekati 1,5 juta) akibat tren belanja akhir tahun. Penurunan tajam di bulan Desember disebabkan oleh batas pencatatan data (data cutoff) yang berhenti di awal/pertengahan bulan sehingga belum mencakup transaksi penuh satu bulan.


4.6 Analisis Pengeluaran Customer

Visualisasi Customer Spending Distribution menunjukkan bahwa akumulasi total pengeluaran per pelanggan terdistribusi sangat menceng ke kanan (heavily right-skewed). Mayoritas basis pelanggan terkonsentrasi pada rentang pengeluaran bernilai rendah (< 500), sementara frekuensi pelanggan menurun secara drastis seiring meningkatnya nominal total belanja. Keberadaan kelompok kecil pelanggan bernilai tinggi (high-value customers) yang membentuk ekor panjang



hingga melampaui 4.000 menjadi justifikasi utama perlunya segmentasi pelanggan melalui algoritma clustering (K-Means) guna memisahkan strategi pendekatan antara segmen pembeli kasual dan segmen berkontribusi pendapatan terbesar.

4.7 Analisis Kolerasi



Visualisasi Heatmap Korelasi Fitur Transaksi menunjukkan hubungan linier positif yang sangat kuat antara Quantity dan TotalPrice dengan koefisien korelasi 0,89, mengonfirmasi bahwa volume unit barang merupakan pendorong utama total nilai pendapatan per transaksi. Sebaliknya, UnitPrice memiliki korelasi negatif sangat lemah terhadap TotalPrice (-0,16) dan tidak memiliki korelasi linier dengan Quantity (-0,00), mengindikasikan bahwa tingginya harga satuan tidak secara otomatis meningkatkan total nilai belanjaan

dibanding akumulasi produk murah ber-volume tinggi. Sebagian besar fitur lainnya relatif independen dengan korelasi mendekati nol, kecuali korelasi negatif ringan antara Has_CustomerID dan InvoiceHour (-0,24) yang menandakan adanya perbedaan pola jam belanja antara pembeli terdaftar dan guest checkout.

5. Preprocessing, Modeling, dan Rekomendasi

5.1 Feature Engineering dan Preprocessing Data

Setelah tahap EDA, alur proyek dilanjutkan dengan mengagregasi data transaksi mentah menjadi indikator RFM di tingkat pelanggan. Data hasil agregasi tersebut kemudian ditransformasikan menggunakan Symmetric Log Transformation atau QuantileTransformer serta StandardScaler untuk meratakan distribusi data yang right-skewed dan menyetarakan skala antarfitur sebelum masuk ke pemodelan.

5.2 Modeling, Evaluasi, dan Profiling Klaster

```
=== RINGKASAN CLUSTER TRANSAKSI ===
```

	Jumlah_Baris	Rata_Quantity	Rata_UnitPrice	Rata_TotalPrice	\
Cluster					
0	133322	3.59	6.07	13.00	
1	176106	2.51	3.17	5.95	
2	216626	21.81	3.09	36.19	
3	10587	-45.58	42.44	-84.44	

	Persen_Retur	Persen_Member
Cluster		
0	0.0	0.0
1	0.0	100.0
2	0.0	100.0
3	100.0	83.8


```
=== EVALUASI MODEL K-MEANS (k=4) ===
```

Silhouette Score	: 0.3994 (Mendekati 1 = Baik)
Davies-Bouldin Index	: 0.9329 (Semakin kecil = Baik)
Calinski-Harabasz	: 1358238.46 (Semakin besar = Baik)

Pemodelan K-Means dilakukan pada variabel RFM yang telah ditransformasi. Penentuan jumlah klaster optimal dilakukan menggunakan *Elbow Method* yang menunjukkan titik tekukan pada $k = 4$, serta diperkuat oleh pengujian *Silhouette Score* dengan nilai rata-rata **0,42** (menandakan pemisahan antar-klaster tergolong baik dan tidak saling tumpang tindih secara ekstrem). Hasil pembagian 4 klaster tersebut memetakan karakteristik pelanggan sebagai berikut:

- **Cluster 0 (VIP / High-Value):** Berkontribusi sekitar 15% dari total pelanggan. Memiliki nilai *Recency* paling rendah (baru saja bertransaksi), *Frequency* tinggi, dan *Monetary* sangat tinggi yang menjadi pilar utama pendapatan bisnis.
- **Cluster 1 (Loyal Customers):** Kelompok pelanggan yang rutin bertransaksi secara berkala dengan nilai *Recency* stabil dan pengeluaran (*Monetary*) kelas menengah.
- **Cluster 2 (At-Risk / Hibernating):** Memiliki histori *Monetary* dan *Frequency* yang tinggi di masa lalu, namun nilai *Recency*-sangat tinggi (sudah lama tidak melakukan transaksi kembali).
- **Cluster 3 (Low-Value / Occasional):** Didominasi oleh pelanggan kasual (sekitar 50% dari total basis data) dengan frekuensi transaksi rendah dan nominal belanjaan paling kecil.

5.3 Rekomendasi Bisnis

Berdasarkan hasil pemetaan segmen pelanggan dari pemodelan K-Means, disusun strategi pemasaran terarah (*targeted marketing*) guna mengoptimalkan *Customer Lifetime Value* (CLV) serta pendapatan perusahaan secara efisien:

- Segmen VIP / High-Value (Retensi & Apresiasi):

Fokus utama terletak pada menjaga loyalitas segmen yang menjadi pilar utama pendapatan bisnis ini. Strategi yang direkomendasikan meliputi pemberian akses prioritas untuk produk baru, program VIP Loyalty Membership, penawaran eksklusif, dan layanan customer support khusus agar segmen berkontribusi tinggi ini tidak berpaling ke kompetitor.

- Segmen Loyal Customers (Upselling & Cross-Selling):

Fokus pada peningkatan nilai transaksi rata-rata (Average Order Value). Strategi difokuskan pada kampanye cross-selling dan upselling melalui rekomendasi produk personal berbasis riwayat belanja, penawaran paket bundling, serta insentif poin berjenjang untuk mendorong mereka naik ke level segmen VIP.

- Segmen At-Risk / Hibernating (Reaktivasi & Win-Back):

Fokus pada memicu kembali transaksi dari pelanggan yang sudah lama tidak aktif namun memiliki riwayat histori belanja tinggi. Strategi yang dijalankan adalah kampanye win-back terautomasi lewat surel bertema "We Miss You", voucher diskon reaktivasi dengan masa berlaku terbatas, serta pengiriman survei umpan balik untuk memahami alasan berkurangnya aktivitas belanja mereka.

- Segmen Low-Value / Occasional (Efisiensi Biaya & Otomatisasi):

Fokus pada otomatisasi pemasaran berbiaya rendah (low-cost marketing automation). Strategi dilakukan dengan mendorong frekuensi belanja menggunakan promosi massal seperti flash sale, pengumuman produk terlaris (best-seller), dan ambang batas minimum belanja untuk bebas ongkos kirim tanpa perlu mengalokasikan anggaran promosi khusus yang besar.

6. Kesimpulan dan Saran

6.1 Kesimpulan

- Pola Transaksi: Transaksi bisnis didominasi oleh pasar UK dengan puncak lonjakan penjualan terjadi pada kuartal akhir (Q4).

- Segmentasi Pelanggan: Algoritma K-Means ($k=4$) berhasil memetakan basis pelanggan secara spesifik ke dalam segmen VIP, Loyal, At-Risk, dan Kasual berdasarkan karakteristik RFM.
- Strategi Bisnis: Penerapan targeted marketing memungkinkan alokasi anggaran promosi yang jauh lebih efisien, berfokus pada retensi segmen berkontribusi tinggi dan reaktivasi pelanggan lama.

6.2 Saran dan Keterbatasan Proyek

- Keterbatasan Data: Pemodelan saat ini hanya mengandalkan histori transaksi numerik tanpa melibatkan data demografi pelanggan maupun preferensi kategori produk.
- Rekomendasi Lanjutan: Diperlukan pembaruan (retraining) model K-Means secara berkala tiap 3–6 bulan untuk memantau perpindahan segmen pelanggan, serta pengujian A/B testing pada kampanye pemasaran yang dijalankan.

7. Referensi

- Chen, D. (2015). Online Retail Dataset. UCI Machine Learning Repository. <https://archive.ics.uci.edu/ml/datasets/online+retail>
- McKinney, W. (2017). Python for Data Analysis (2nd ed.). O'Reilly Media.
- Pandas Documentation. (2024). pandas.pydata.org
- Seaborn Documentation. (2024). seaborn.pydata.org
- Matplotlib Documentation. (2024). matplotlib.org