

Nama: Renjiro Wiroskid Angga

NIM: 2802522531

1. Review & Evaluation of Data Quality

a. Summarize the main data quality issues:

Masalahnya adalah missing values yang sangat banyak pada kolom CustomerID yakni 135.080 baris atau 24,93% dan kolom Description ada 1.454 baris. Lalu ada 5.628 baris data duplikat. Ditemukan juga 10.624 baris nilai negatif pada kolom Quantity dan nilai nol pada UnitPrice. InvoiceDate juga belum menggunakan format datetime. Outlier ditemukan pada beberapa kolom dengan menggunakan metode IQR. Outlier dapat menimbulkan distorsi pada tahap analisis .

b. Evaluate data wrangling effectiveness:

Penghapusan missing values(dropna pada CustomerID), data duplikat, dan penyaringan transaksi tidak valid (kuantitas negatif dan harga nol) memastikan bahwa dataset hanya berisi riwayat transaksi pembelian riil yang sah. Transformasi tipe data ke bentuk datetime juga supaya analisis dengan timeline waktu dapat dilakukan, sedangkan, menambahkan/membuat kolom baru yaitu TotalPrice digunakan untuk mendukung analisis. Kolom ini dibuat dari mengkalikan kolom Quantity dengan kolom UnitPrice. Outlier dihapus menggunakan metode IQR untuk setiap kolom numerik supaya tidak ada anomaly.

c. Support with Indicators:

Keberhasilan proses ini didukung oleh indikator perbandingan dimensi data, di mana dataset awal yang berjumlah 541.909 baris berhasil dibersihkan dan menyusut menjadi 319.806 baris. Artinya, metode pembersihan (termasuk penggunaan IQR untuk menghapus outlier) secara efektif telah membuang 222.103 baris (40,99%) data yang mengandung noise atau anomali, sehingga model statistika selanjutnya terbebas dari distorsi

2. Advanced Pattern, Trend, and Relationship Analysis

a. Extend exploratory analysis:

- **Time-based:** Pola penjualan menunjukkan tren kenaikan dalam tahun dengan puncak tertinggi di bulan November. Transaksi selalu memuncak pada tengah hari (jam 12.00 WIB - 13.00 WIB).
- **Subgroup (Geografis & RFM):** United Kingdom menjadi negara paling dominan dari penjualan e-commerce ini yang memiliki kontribusi terbesar sebanyak 92% dari total pendapatan. Ini menunjukkan bahwa e-commerce ini berpusat di pasar domestic. Perilaku pelanggan: mayoritas pelanggan berbelanja dalam jumlah dan nilai kecil, sementara segelintir high-value customers menyumbang proporsi pendapatan yang luar biasa masif.

b. Identify the most influential variables:

Variabel yang paling berpengaruh untuk total transaksi adalah Quantity serta metrik historis pelanggan seperti pola keseringan bertransaksi (Frequency dari perhitungan RFM).

c. Explain why relationships are meaningful (analytical evidence):

Hubungan ini terbukti bermakna pada matriks korelasi. Variabel Quantity memiliki nilai korelasi positif tertinggi terhadap TotalPrice yaitu 0,50 menunjukkan jika semakin banyak item dibeli maka semakin tinggi juga nilai transaksi, berbanding terbalik dengan korelasi UnitPrice yang lebih rendah (0,28) menunjukkan jika harga mempengaruhi nilai transaksi tetapi tidak sebesar Quantity.. Selain itu, evaluasi RFM menunjukkan skor korelasi positif yang sangat kuat (0,79) antara Frequency dan Monetary. Ini menyimpulkan bahwa faktor tumuhnya pendapatan adalah volume barang yang terjual dan frekuensi kunjungan pelanggan (loyalitas), bukan sekadar harga barang itu sendiri.

3. Evaluation of Analytical Methods and Metrics

a. Describe analytical techniques/models used:

Descriptive Statistics dan Distribution Analysis (Histogram, Boxplot) untuk memetakan pemusatan dan sebaran frekuensi data numerik. Proyek ini juga menggunakan metode matriks korelasi Heatmap untuk menganalisis hubungan antar-variabel, dan menggunakan model skoring RFM (Recency, Frequency, Monetary) Analysis untuk mengelompokkan karakteristik perilaku belanja masing-masing pelanggan (Customer Segmentation).

b. Select and explain evaluation metrics:

kekuatan korelasi (koefisien r) yang divisualisasikan menggunakan heatmap. Indikator ini merangkum rentang korelasi linier di mana nilai yang mendekati 1 (seperti Frequency-Monetary di angka 0,79) menggambarkan kesinambungan linier yang kokoh. Selain itu, teknik perbandingan kuartil (Q1, Q2/Median, Q3) dan IQR dipakai untuk mengukur skewness (kemiringan), sehingga disimpulkan bahwa karakteristik konsumen bersifat right-skewed (transaksi didominasi keranjang kecil)

c. Discuss limitations:

Penghapusan outlier yang sangat agresif (mencapai pemotongan ~41% data menggunakan batas IQR murni). Dalam skenario e-commerce, outlier volume pembelian yang sangat masif sering kali merupakan transaksi sah, bukan kesalahan input. Penghapusan ini memunculkan kelemahan di mana wawasan terkait potensi besar korporat atau pelanggan elit tidak tertangkap.

4. Exploratory Data Analysis (EDA) / Recommendations

a. Propose actionable recommendations:

- **Rekomendasi 1:** Perusahaan sebaiknya melakukan Pre-holiday promotion karena puncak penjualan terjadi pada bulan november

atau menjelang liburan. Pemasaran ini dapat dilakukan mulai dari bulan september untuk memaksimalkan puncak periode penjualan.

- **Rekomendasi 2:** Perbanyak stok untuk produk yang menghasilkan total revenue yang banyak, terutama WHITE HANGING HEART T-LIGHT HOLDER sebelum musim liburan. Bersamaan dengan itu, kembangkan program insentif bagi kelompok pelanggan dengan frekuensi dan pengeluaran tinggi (high RFM score) untuk merawat retensi mereka.

b. Explain how they support decision making:

Membantu tim Pemasaran (Marketing) dalam mengalokasikan modal biaya promosi hanya ke jam operasional dan hari yang menghasilkan profit tertinggi (Tengah hari & kuartal ke-4). Bagi tim Penyedia Stock, dengan mengetahui produk unggulan, manajemen gudang jadi dapat mencegah terjadinya out-of-stock pada momen krusial akhir tahun.

c. Discuss potential risks or considerations:

- **Risiko Overstocking & Biaya Simpan:** Jika perencanaan inventaris untuk musim liburan hanya mengandalkan kinerja bulan November tahun lalu, terdapat risiko penumpukan "stok mati" (inventaris yang tidak bergerak) apabila terjadi perubahan perilaku konsumen atau penurunan angka beli.
- **Risiko Ketergantungan High-Value Customer:** Karena pendapatan sangat bergantung pada kelompok pelanggan tertentu, perusahaan menghadapi risiko konsentrasi pendapatan. Jika beberapa pelanggan dengan frekuensi transaksi tinggi beralih ke pesaing, platform e-commerce tersebut akan mengalami penurunan pendapatan yang signifikan dan tidak proporsional.